

## WSI - zadanie 5

### Sztuczne sieci neuronowe Perceptrony wielowarstwowe

Treść zadania:


Zaimplementuj perceptron wielowarstwowy, który posłuży do aproksymacji zadanej funkcji  $f(x)$ . Zbadaj wpływ liczby neuronów w warstwie na jakość uzyskanej aproksymacji.

Rozwiązanie biblioteki sklearn - model sieci MLPRegressor

W pliku plot.py przygotowaliśmy funkcję rysującą wykresy i dodatkowo zbadaliśmy wpływ parametrów na przybliżenia funkcji przez model sieci neuronowej z biblioteki sklearn.

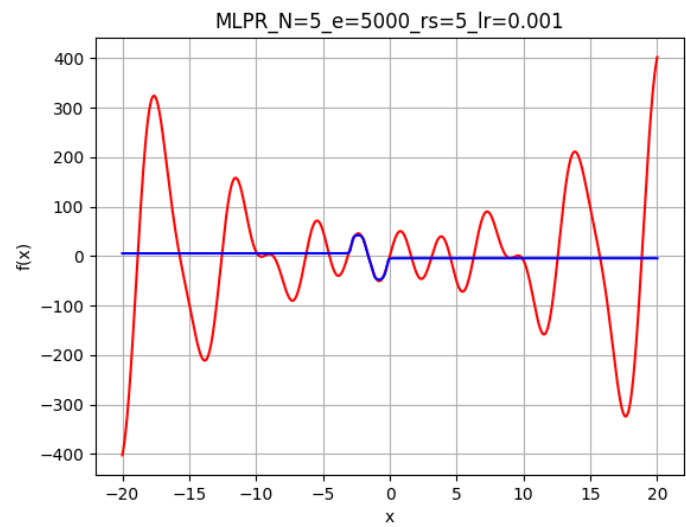
Za pomocą tego modelu najlepsze wyniki otrzymano dla poniższych parametrów. Na następnej stronie znajduje się zestawienie aproksymacji funkcji dla różnej liczby perceptronów w warstwie ukrytej. I dla stałej wartości pozostałych parametrów.

Neurony=30, epoki=5000, mini\_batch=100, learning\_rate=0.001, random\_state=5,  
funkcja aktywacji=sigmoidalna, solver=SGD




Następnych stronach aproksymacja funkcji względem liczby neuronów:


Liczba neuronów: 5




Liczba neuronów: 10



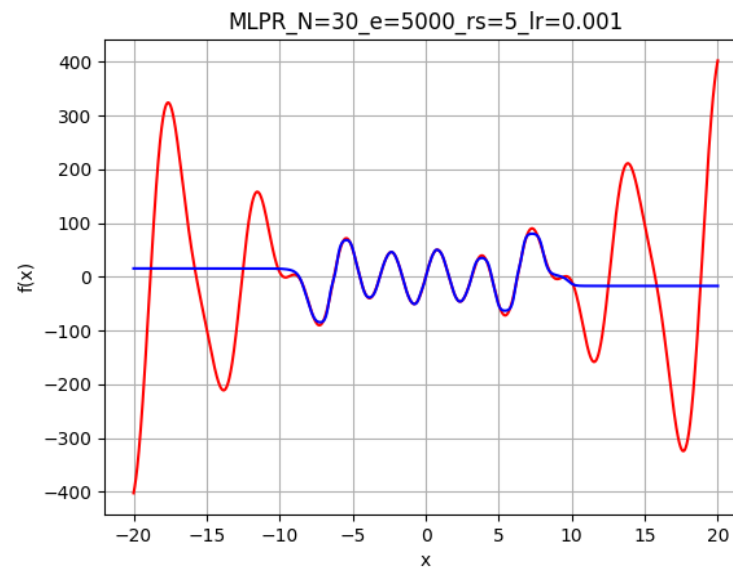
Liczba neuronów: 20



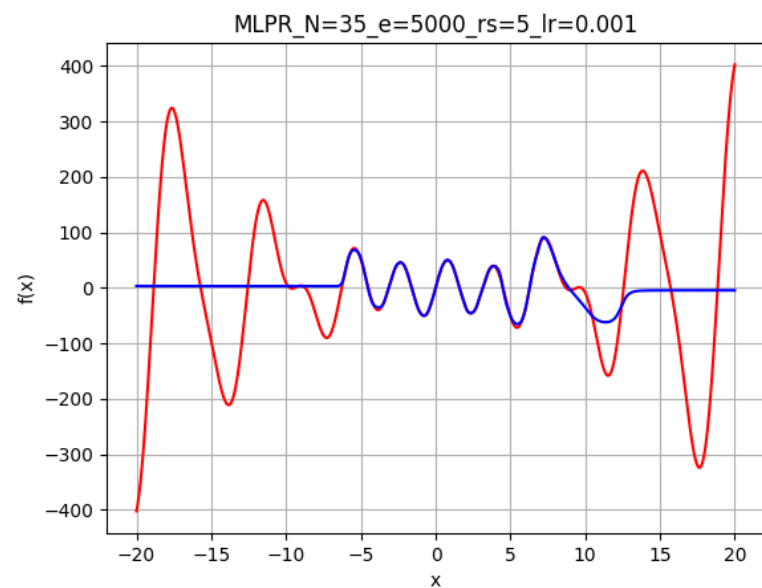
Liczba neuronów: 25




Liczba neuronów: 30




Liczba neuronów: 35



Liczba neuronów: 40



Liczba neuronów: 45




### Badanie pozostałych parametrów

Stworzyliśmy kilka modeli dla różnych wartości parametru `random_state` odpowiedzialnego za początkowe wylosowane wartości wag i biasów dla warstwy ukrytej. Nie miało to większego wpływu na wyniki, ale najlepsze przybliżenie dostaliśmy dla wartości 5, dlatego jej używamy w pozostałych doświadczeniach.


Parameter learning rate należało dostosować do rozmiaru zbioru testującego. Dla 40 000 próbek, najlepiej sprawdzała się wartość 0,001, co demonstrują poniższe wykresy.

## Learning rate


Learning rate: 0.01



Learning rate: 0.001




Learning rate: 0.0001




## Nasze rozwiązanie


Liczba neuronów: 5




Liczba neuronów: 10




Liczba neuronów: 15




Liczba neuronów: 20



Liczba neuronów: 25



Liczba neuronów: 30



## Analiza naszego rozwiązania

Zaimplementowany przez nas algorytm jest niestabilny, nie zawsze dobrze aproksymuje zadaną funkcję. Na wykresie z 15 neuronami niebieska linia przypomina funkcję o przeciwnych wartościach do danej. Dodatkowo większa liczba epok wcale nie wpływała na poprawę aproksymacji. Algorytm najlepiej zachowywał się dla 10-15 neuronów. Dlatego przeprowadziliśmy dodatkowe badanie w tym zakresie. Oto najlepsze przybliżenie jakie otrzymaliśmy, dla 12 neuronów:

